

Gramática de Gráficos.

Máster Universitario en Ciberseguridad e Inteligencia de Datos

Gramática de gráficos:

- Gramática: Principios y reglas fundamentales de un arte o ciencia.
- Una gramática es un conjunto de reglas estructurales que ayuda a definir y establecer los componentes de una lengua.
- Una **gramática de gráficos** es un marco que permite describir de forma concisa los componentes de cualquier gráfico.
- En lugar de pruebas ensayo-error sigue una estructura establecida para construir una visualización a partir de componentes y reglas definidos en la gramática.
- Se generan gráficos de forma **declarativa** en lugar de **imperativa**.



Gramática de gráficos de Wilkinson:

- La definición original de gramática de gráficos se debe a **Leland Wilkinson**, que estableció los aspectos principales de su gramática para obtener una visualización de datos efectiva.
- Sistema con 7 conjuntos de componentes cuyos elementos son aspectos del sistema general
- Cada combinación de aspectos es significativo.
- Alto grado de expresividad al sistema



Gramática de gráficos de Wilkinson:

- Arquitectura de flujo de datos: *pipeline*.
- Pipeline: secuencia de **mapeos** que se necesitan para generar un gráfico estadístico. Se pasa por los espacios.
 - Datos
 - Conjunto de variables
 - Gráficos
 - Gráficos estéticos
- Componentes: ***Variables, Álgebra, Escalas, Estadísticas, Geometría, Coordenadas, Estéticas (representaciones que se pueden percibir).***




Gramática de gráficos de Wilkinson:


- Las subtarefas necesarias para producir un gráfico requieren un orden específico.
 - Por ejemplo: las transformaciones estadísticas deben generarse después de las escalas
- El flujo de datos está parametrizado, permitiendo establecer diferentes flujos:
 - diseños: factorial, anidado, ...
 - escalas: lineal, logarítmica, probabilidades, ...
 - métodos estadísticos: media, mediana, moda, suavizado, ...
 - sistemas de coordenadas: cartesianas, polares, ...
 - estéticas: tamaño, forma, color, relleno, tipo de línea...



Gramática de gráficos de Wilkinson:



Gramática de gráficos de Wilkinson:



Algebra

Escala

Estadística


Gramática de gráficos de Wilkinson:

- Los datos provienen de **fuentes diversas**: tablas de bases de datos relacionales, json, XML, bases de datos no relacionales, ...
- Los datos se deben convertir a **variables estadísticas**, generalmente columnas en una tabla estadística.
- **Álgebra de gráficos**: operadores que permiten combinar las variables en para componer y balancear conjuntos de variables para crear las tablas.
 - **cross** → join
 - **nest** → Obtener datos de una variable en función de los de otra
 - **blend** → Union
- **pandas, Dplyr**



Gramática de gráficos de Wilkinson:


- **Escalas:** forma en que se mapean las variables a estéticas
- Ajustan los datos para adecuarlos a algo que se puede ver y proporcionan herramientas que ayudan a interpretar el gráfico.
 - **Necesario para conocer la conversión de los números a unidades de medida que el ordenador pueda renderizar, por ejemplo coordenadas de pixel o color.**
- Las medidas indican cuánta distancia en la región del marco del gráfico corresponde a los rangos de las variables que definen la región.
- Determinan cómo percibimos tamaño-forma-posición
- Afectan a ejes, leyendas, escalas y otras anotaciones.
- Se deben definir antes de calcular estadísticas.
 - Especialmente si se van a usar logaritmos.



Gramática de gráficos de Wilkinson:

- **Escalas**

Población	Habitantes
A	10.000
B	50.000
C	100.000



- Si el gráfico tiene una altura total de 500 píxeles, la escala lineal asignará:
 - Ciudad A (10,000 personas) → 50 píxeles
 - Ciudad B (50,000 personas) → 250 píxeles
 - Ciudad C (100,000 personas) → 500 píxeles

10,000 personas equivalen a 50 píxeles en la escala.



Gramática de gráficos de Wilkinson:

- **Ejemplo:**


Ingresos anuales de varias personas:

20,000 €

30,000 €

50,000 €

1,000,000 € (outlier)



La media aritmética es muy alta debido al outlier (275.000€), mientras que la media logarítmica (74.008€) dará un valor más representativo de la mayoría de los datos.

Asegurar que la escala elegida tiene sentido para lo que quieres comunicar.




Gramática de gráficos de Wilkinson:

- Estadísticas:
 - Forman parte del sistema que define la arquitectura
 - Son independientes a los elementos geométricos.
 - Reciben un conjunto de variables, computan las estadísticas y la salida es otro conjunto de variables.
 - scatterplot → identidad
 - histograma → frecuencia de intervalos




Gramática de gráficos de Wilkinson:

- Geometría: Elementos que se mostrarán
 - punto, texto, línea, barras, ...
- Coordenadas: Dónde se ubican los elementos que se mostrarán
- Estéticas:
 - forma, color, relleno, ...



Gramática de gráficos de Wickham:


- Adaptación de la gramática de gráficos de Wilson → **ggplot** **plotnine**
- Se define el gráfico de forma **declarativa**
- Se especifica (declara) de qué **capas** está formado el gráfico:
 - **datos, estéticas, geometrías, coordenadas, estadísticas, facetas, tema**
 - En ggplot los datos y las capas de mapeo son obligatorias, las restantes opcionales. (se toman valores por defecto).



Gramática de gráficos de Wickham:

Fuente:

<https://r.qcbs.ca/workshop03/book-en/grammar-of-graphics-gg-basics.html>



```
ggplot(data = <DATA>) +  
  <GEOM function>(mapping=aes(<mappings>),  
    stat = <STAT>, position = <POSITION> ) +  
  <COORDINATE function> +  
  <SCALE function> +  
  <THEME function> +  
  <FACET function> +...
```

Required

Not required



Gramática de gráficos de Wickham:

- Adaptación de la gramática de gráficos de Wilson → **ggplot** **plotnine**
- Proceso de construir un gráfico:
 - Se parte de un Dataset
 - Se mapean las variables a elementos que se pueden percibir (aesthetics):
 - tamaño, forma, color, ...
 - Se eliminan las que no aparecerán
 - Selección de elementos geométricos.
 - puntos → scatterplot
 - línea → diagrama de líneas
 - barra → diagrama de barras



Gramática de gráficos de Wickham:

- Sistema de coordenadas.
 - Establecer de qué forma se ubican en el plano 2D las estéticas.
- Escalas: Convertir las unidades de datos a unidades de elementos que se perciben en el gráfico
- Transformación estadística:
 - scatterplot → identidad
 - histograma → frecuencia del intervalo



Gramática de gráficos de Wickham:

- Capa: se crean los objetos que percibimos en el gráfico
 - Datos y mapeo de los datos a estéticas.
 - Objetos geométricos.
 - Transformaciones estadísticas.
 - Escala para cada estética
 - Sistema de coordenadas
 - Partición (faceting)
- Un gráfico puede estar formado por varias capas
- Generalmente todas las capas de un gráfico tienen algo en común.



Gramática de gráficos de Wickham:

- Estéticas: características que se pueden percibir en el gráfico a las que mapeamos las variables
 - posición
 - tamaño
 - forma
 - color
 - relleno
 - transparencia
 - etiquetas
- Cada geometría sólo muestra ciertas estéticas, no se pueden asignar arbitrariamente.
 - punto → posición, forma y tamaño.
 - barra → posición, alto, ancho y color de relleno



Gramática de gráficos de Wickham:

- Objetos geométricos: controlan el tipo de gráfico.
 - Objeto geométrico point → scatterplot
 - Objeto geométrico línea → gráfico de líneas.
- Se clasifican por su dimensión:
 - 0d → punto, texto
 - 1d → camino, camino ordenado, línea
 - 2d → polígono
- Ajuste de posición: para que no haya solapamiento,
 - espaciado en las barras
 - pequeña fluctuación aleatoria para que no haya sobre dibujado en los puntos.



Gramática de gráficos de Wickham:

- Transformación estadística: Resume los datos de alguna manera
- Deben ser invariantes a la traslación y escalado.
- Se pueden añadir al conjunto de variables y por tanto mapear a estéticas.
- Según la estadística que se aplique podemos obtener diferentes tipos de gráficos.
- Es necesario seleccionar el método acorde al sistema de coordenadas que se utilice.
 - **coordenadas polares** → **regresión circular**
- Ejemplos:
 - **bin** → **frecuencia de intervalo**
 - **smooth** → **suavizado**
 - **jitter** → **ruido**
 - **identidad**
 - **densidad**
 -



Gramática de gráficos de Wickham:

- Facetting: Se subdivide el dataset, lo que permite generar múltiples gráficos.
- Análisis multidimensional:
 - **4 variables:** posición (2), tamaño, forma
 - **3 gráficos de subconjuntos** por el valor de una variable
- Ventajas:
- Facilita la interacción del usuario.
 - **Se puede modificar de forma independiente sólo los elementos que sean necesarios.**
- Permite definir gráficos adaptados a problemas particulares.
- Facilita el desarrollo:
 - **Se pueden agregar componentes que permitan descubrir nuevos tipos de gráficos.**



Característica	Wilkinson (2005)	Wickham (2009) (ggplot2)
Enfoque	Teórico, formal y modular.	Pragmático, diseñado para implementación.
Componentes	7 (Variables, Álgebra, Escalas, Estadísticas, Geometría, Coordenadas, Estéticas).	7 (datos, estéticas, geometrías, coordenadas, estadísticas, facetas, tema).
Flexibilidad	Muy flexible, pero difícil de implementar.	Estructura más rígida pero más fácil de usar.
Uso	Base para herramientas como Tableau y Vega-Lite.	Implementación directa en ggplot2 en R.



Ejemplo:

- Histograma:
 - Geometría: barras
 - Transformación estadística: frecuencia del intervalo
 - Mapeo de la transformación estadística a la estética: altura de la barra
- La separación entre estadística y geometría facilita variar el aspecto del histograma




Ejemplo:

- Pie char:
 - Sistema de coordenadas polares
 - Geometría: barras
 - La coordenada radio es constante
 - La variable se mapea al ángulo
- Otros gráficos similares:
 - Rosa de Florence Nightingale: Sistema de coordenadas polar, la y se mapea al ángulo, la x al relleno.
 -




Ejemplo:



¿Cómo se define en términos de gramática de gráficos por capas o de Whickham?.



Ejemplo:



Dos datasets: ciudades y tropas

Ciudad: posición y nombre

Tropas: posición, dirección (A, R), número de supervivientes

Camino: Datos de tropa

dirección se mapea a color

supervivientes se mapea a ancho de la línea.

Mapeo de la posición de las ciudades a coordenadas.

Se evitan bucles, muy costosos computacionalmente.



